Eserciziario di Calcolo Numerico
Tiziano Cazzato

Dagli esami del prof

# Analisi dell'errore

## Sezione Quiz

3. $\boxed{\text{2 Punti}}$ Sia $x \in \mathbb{R}$ e $\widetilde{x} = \mathrm{RN}(x)$ il numero floating point corrispondente ad $x$ ottenuto con il metodo di arrotondamento *round-to-nearest*. Inoltre si denota con $u$ la precisione di macchina e si assume che l'arrotondamento di $x$ non generi overflow ed underflow. Da queste informazioni possiamo dedurre che:
   - ☐ $|x - \widetilde{x}| \leq \frac{1}{2}u$.
   - ☐ Se $x \neq 0$ allora $\frac{|x-\widetilde{x}|}{|x|} \leq \frac{1}{2}u$.
   - ☐ $x$ e $\widetilde{x}$ hanno lo stesso segno o sono entrambi nulli.
   - ☐ $\mathrm{RN}(x^2) = (\widetilde{x})^2$.
   - ☐ $\mathrm{RN}(\widetilde{x}) = \widetilde{x}$.
   - ☐ Nessuna delle precedenti.

1. $\boxed{\text{2 Punti}}$ Siano $x, y, z \in \mathbb{R}$ **numeri floating point**, ovvero esattamente rappresentati nel formato in virgola mobile, e si indica con RN il metodo di arrotondamento *round-to-nearest*. Inoltre si denota con $u$ la precisione di macchina e, nelle affermazioni che seguono, si assume che non vengano generati errori di overflow ed underflow.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ In generale $\mathrm{RN}(x + y) \neq \mathrm{RN}(y + x)$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ In generale $\mathrm{RN}(\mathrm{RN}(x + y) + z) \neq \mathrm{RN}(x + \mathrm{RN}(y + z))$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ In generale $x \cdot \mathrm{RN}(x^{-1}) \neq 1$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ In generale $x \cdot \mathrm{RN}(x)^{-1} \neq 1$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Nel caso si usi il formato *precisione doppia*, rappresentare $x$ richiede 32 bit.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Nel caso si usi il formato *precisione doppia*, si ha $u \approx 2.22 \times 10^{-16}$.

2. $\boxed{\text{2 Punti}}$ Sia $F(\beta, m, L, U) \subset \mathbb{R}$ l'insieme dei numeri di macchina con base $\beta \in \mathbb{N}$, mantissa di lungezza $m \in \mathbb{N}$ ed esponente fra $L$ ed $U$; ovvero i numeri reali $x \in \mathbb{R}$ della forma

$$x = \mathrm{segno}(x) \cdot \beta^e \cdot \sum_{j=1}^{m} \alpha_j \beta^{-j},$$

con $e \in \mathbb{Z}$, $L \leq e \leq U$ e $\alpha_j \in \{0, \ldots, \beta - 1\}$, $\alpha_1 \neq 0$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Tutti i numeri interi sono contenuti in $F(\beta, m, L, U)$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ I numeri di macchina sono equispaziati sulla retta reale.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Se $x \in F(\beta, m, L, U)$ allora $x^{-1} \in F(\beta, m, L, U)$.



$\boxed{\text{V}}$ $\boxed{\text{F}}$ Se $x, y \in F(\beta, m, L, U)$ allora $x \cdot y \in F(\beta, m, L, U)$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Nella rappresentazione floating point con precisione doppia si ha $m = 24$ (23 bit per la mantissa dato che $\alpha_1 = 1$ non va memorizzato).

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Nella rappresentazione floating point con precisione doppia si ha $m = 53$ (52 bit per la mantissa dato che $\alpha_1 = 1$ non va memorizzato).

1. $\boxed{\text{2 Punti}}$ Sia $F(2, m, L, U) \subset \mathbb{R}$ l'insieme dei numeri di macchina con base 2, mantissa di lungezza $m \in \mathbb{N}$ ed esponente fra $L$ ed $U$; ovvero i numeri reali $x \in \mathbb{R}$ della forma

$$x = \text{segno}(x) \cdot 2^e \cdot \sum_{j=1}^{m} \alpha_j 2^{-j},$$

con $e \in \mathbb{Z}$, $L \leq e \leq U$ e $\alpha_j \in \{0, 1\}$, $\alpha_1 = 1$.

Il massimo numero contenuto in $F(2, m, L, U)$ è $\boxed{\phantom{xxxx}}$

Supponiamo di volere memorizzare una matrice $A \in \mathbb{R}^{20\times 10}$ le cui entrate $A$ siano numeri floating point in **precisione singola**; questa operazione richiede $\boxed{\phantom{xxxx}}$ **bit**.

2. $\boxed{\text{2 Punti}}$ Si supponga di lavorare con l'insieme dei numeri floating point, ovvero rappresentati nel formato in virgola mobile, in precisione doppia e si indichi con RN il metodo di arrotondamento round-to-nearest. Inoltre si denotino con $a, b, c$ numeri floating point e con $u = 2^{-52}$ la precisione di macchina.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $RN(1 + u) = 1 + u$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $RN(10 + u) - 10 = u$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $RN(a - b) = (a - b)(1 + \epsilon)$ con $|\epsilon| \leq u$.



$\boxed{\text{V}}$ $\boxed{\text{F}}$ $RN(a \cdot b) = (a \cdot b)(1 + \epsilon)$ con $|\epsilon| \leq u$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $RN(RN(a + b) + c) = RN(a + RN(b + c))$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $(RN(a) + RN(b)) + c = a + (RN(b) + RN(c))$.

4. $\boxed{\text{2 Punti}}$ Siano $x, y \in \mathbb{R}$ e $\widetilde{x} = \text{RN}(x), \widetilde{y} = \text{RN}(y)$ i corrispondenti numeri floating point in precisione doppia, ottenuti con il metodo di arrotondamento round-to-nearest. Inoltre assumiamo, per questo esercizio, di non incontrare mai situazioni di overflow ed underflow. Da queste informazioni possiamo dedurre che:

$\boxed{\text{V}}$ $\boxed{\text{F}}$ Tenere in memoria le due rappresentazioni di $\widetilde{x}$ ed $\widetilde{y}$ occupa 8 bytes.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $x \cdot \widetilde{x} \cdot y \cdot \widetilde{y} \geq 0$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $(x - \widetilde{x})(y - \widetilde{y}) \geq 0$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $\text{RN}(x + y) = \text{RN}(x) + \text{RN}(y)$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $\text{RN}(\widetilde{x} + \widetilde{y}) = \text{RN}(\text{RN}(\widetilde{x}) + \text{RN}(\widetilde{y}))$.

$\boxed{\text{V}}$ $\boxed{\text{F}}$ $\text{RN}(x + y) = \text{RN}(y + x)$.

1. 2 Punti Si consideri la formula

$$f(x, y) = (x - y)(y^2 - x).$$

Indicando con $\epsilon_x, \epsilon_y$ gli errori relativi di arrotondamento sui due input e con $\epsilon_1, \epsilon_2, \ldots$ gli errori relativi di arrotondamento dopo le varie operazioni aritmetiche, si calcolino:

l'errore relativo inerente

l'errore relativo algoritmico

sezione esercizi

## Esercizio 2

Si considerino le funzioni

$$f_1(x) = \frac{1}{1+x} - \frac{1}{1-x},$$
$$f_2(x,y) = (x+1)x + y = (x^2+x) + y.$$

(i) $\boxed{\text{2 Punti}}$ Si scriva l'espressione del coefficiente di amplificazione dell'errore relativo $\gamma(x)$ per $f_1(x)$.

(ii) $\boxed{\text{6 Punti}}$ Si calcoli l'errore algoritmico relativo dei due algoritmi (formule) indicati per la valutazione di $f_2(x,y)$. Si commenti su quale dei due può soffrire più spesso di cancellazione numerica.

## Esercizio 2

Si consideri l'insieme $\mathcal{F}$ dei numeri floating point rappresentati utilizzando la notazione esponenziale normalizzata in base 10 con 3 cifre per la mantissa ed esponente intero fra $-98$ e 100:

$$\mathcal{F} = \left\{ x \in \mathbb{R} : \ x = \text{segno}(x) \cdot 10^e \sum_{j=1}^{3} \alpha_j 10^{-j}, \ \alpha_j \in \{0,1,\dots,9\}, \ \alpha_1 \neq 0, \ e \in \{-98,-97,\dots,99,100\} \right\}.$$

(i) $\boxed{\text{2 Punti}}$ Calcolare il piú piccolo ed il piú grande numero positivo nell'insieme $\mathcal{F}$.

(ii) $\boxed{\text{3 Punti}}$ Utilizzando l'arrotondamento round-to-nearest (arrotondando per eccesso quando la prima cifra trascurata è 5), si calcoli il risultato di

$$\frac{(x+2)^2 - 4}{x}$$

per $x = 6.00 \cdot 10^{-3}$, nell'aritmetica floating point su $\mathcal{F}$. **Si scrivano nel dettaglio i risultati delle operazioni intermedie considerando gli effetti dell'arrotondamento**.

(iii) $\boxed{\text{3 Punti}}$ Si ripeta il calcolo precedente per $x = 2.00 \cdot 10^{-3}$ e si determini l'errore relativo della quantità calcolata.

## Esercizio 3

Si consideri il calcolo in aritmetica floating point della funzione

$$f(x,y) = \frac{x^2}{y} + \frac{x}{y^2}.$$

(i) $\boxed{\text{3 Punti}}$ Si fornisca un algoritmo per il calcolo di $f(x,y)$ che impieghi **esattamente** 4 **operazioni aritmetiche**.

(ii) $\boxed{\text{5 Punti}}$ Si fornisca l'espressione dell'errore relativo algoritmico $\varepsilon_a$ per l'algoritmo del punto $(ii)$.